Sistema de Previsão e Monitoramento de Geração de Energia Solar Fotovoltaica Baseado em Aprendizado de Máquina

João Pedro Pereira Frutuoso, Thallisson Douglas de Freitas Nunes
Departamento de Ciências Exatas e Naturais, Universidade Federal Rural do Semi-Árido (UFERSA)
Mossoró, RN, Brasil

Resumo

A geração de energia solar fotovoltaica depende fortemente das condições climáticas, o que torna o planejamento operacional e a manutenção de usinas tarefas desafiadoras para os gestores. Este trabalho apresenta um sistema de apoio à decisão baseado em aprendizado de máquina, construído a partir do dataset público Solar Power Generation Data. O sistema combina um modelo de regressão, que estima a potência de saída esperada (CA) a partir de variáveis climáticas (irradiação, temperatura do módulo, temperatura ambiente e hora do dia), com um modelo de classificação, que sinaliza períodos de baixa geração para apoiar o planejamento de manutenções. Foram comparados os algoritmos de Regressão Linear/Logística, Random Forest e Redes Neurais (MLP), avaliados por RMSE, MAE e R^2 (regressão) e por acurácia e AUC-ROC (classificação). O Random Forest apresentou o melhor desempenho em ambas as tarefas (R^2 = 0,848; acurácia = 0,928; AUC-ROC = 0,975). Por depender apenas de variáveis climáticas, e não de leituras instantâneas do inversor, o mesmo modelo serve tanto para previsão quanto para monitoramento, ao comparar a geração real com a esperada. Um protótipo de interface interativa foi desenvolvido para apresentar os resultados ao gestor da usina.

Palavras-chave: *Energia solar fotovoltaica; Aprendizado de máquina; Sistema de apoio à decisão; Regressão; Classificação.*

Abstract

Photovoltaic solar power generation depends heavily on weather conditions, which makes operational planning and plant maintenance challenging tasks for managers. This work presents a machine learning-based decision support system built from the public Solar Power Generation Data dataset. The system combines a regression model, which estimates the expected AC power output from weather variables (irradiation, module temperature, ambient temperature and time of day), with a classification model that flags low-generation periods to support maintenance scheduling. Linear/Logistic Regression, Random Forest and Neural Networks (MLP) were compared and evaluated using RMSE, MAE and R^2 (regression) and accuracy and AUC-ROC (classification). Random Forest achieved the best performance on both tasks (R^2 = 0.848; accuracy = 0.928; AUC-ROC = 0.975). Because it relies solely on weather variables, and not on instantaneous inverter readings, the same model supports both forecasting and monitoring, by comparing actual against expected generation. An interactive interface prototype was developed to present the results to the plant manager.

Keywords: *Photovoltaic solar energy; Machine learning; Decision support system; Regression; Classification.*

1. Introdução

A energia solar fotovoltaica é uma das fontes renováveis com maior crescimento no Brasil, especialmente em regiões de alta incidência solar como o Semiárido. Esse crescimento exige ferramentas que apoiem os gestores de usinas na operação diária: estimar quanto será gerado em determinadas condições climáticas e identificar quando a geração observada está abaixo do esperado, indicando possível falha de equipamento, sujeira nos painéis ou outro problema operacional.

Tradicionalmente, esse acompanhamento é feito por meio de médias históricas, inspeções periódicas ou pela experiência da equipe de operação. Técnicas de aprendizado de máquina permitem automatizar parte desse processo, aprendendo a relação entre as condições climáticas e a geração de energia a partir de dados históricos, e usando essa relação tanto para prever a geração futura quanto para avaliar, em tempo real, se a geração atual está dentro do esperado.

Este trabalho tem como objetivo geral desenvolver um sistema de apoio à tomada de decisão para gestores de usinas solares fotovoltaicas, baseado em aprendizado de máquina. Os objetivos específicos são: (i) realizar uma análise exploratória do conjunto de dados, identificando os fatores que mais influenciam a geração de energia; (ii) construir e comparar modelos de regressão capazes de estimar a potência de saída esperada a partir de variáveis climáticas; (iii) construir e comparar modelos de classificação capazes de prever períodos de baixa geração, como apoio ao planejamento de manutenções; e (iv) desenvolver um protótipo de interface interativa que apresente esses resultados de forma acessível ao gestor.

A escolha do problema se justifica por dois motivos. Primeiro, trata-se de um problema real e de relevância social e econômica, alinhado ao potencial de geração solar da região semiárida onde este trabalho foi desenvolvido. Segundo, o problema permite explorar, de forma integrada, técnicas de regressão, classificação e ensembles estudadas na disciplina, com um único objetivo orientando todas as etapas: usar apenas variáveis climáticas para que o mesmo modelo sirva tanto para previsão quanto para monitoramento da usina.

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica

sobre os algoritmos e métricas utilizados; a Seção 3 descreve a metodologia, incluindo o conjunto de dados, o pré-processamento e a definição dos atributos e alvos; a Seção 4 apresenta os resultados da análise exploratória, dos modelos de regressão e classificação, e do protótipo de interface; e a Seção 5 apresenta as conclusões, dificuldades encontradas, aprendizados e propostas de trabalhos futuros.

2. Fundamentação Teórica

2.1. Aprendizado supervisionado: regressão e classificação

No aprendizado supervisionado, o modelo é treinado a partir de exemplos rotulados, compostos por um conjunto de atributos de entrada (features) e um valor de saída conhecido (alvo). Quando o alvo é um valor numérico contínuo, a tarefa é chamada de regressão; quando o alvo é uma categoria discreta, a tarefa é chamada de classificação. Este trabalho aborda ambas as tarefas: a regressão estima a potência de saída em corrente alternada (AC_POWER, em kW), enquanto a classificação prevê se um determinado período terá baixa geração.

2.2. Algoritmos utilizados

Regressão Linear e Logística: a Regressão Linear modela o alvo como uma combinação linear ponderada dos atributos de entrada, sendo amplamente utilizada como modelo de referência (baseline) por sua simplicidade e interpretabilidade. A Regressão Logística aplica uma função sigmoide sobre essa combinação linear, retornando uma probabilidade entre 0 e 1, sendo o modelo de referência para classificação binária.

Random Forest: é um método de ensemble baseado em árvores de decisão, que combina as previsões de múltiplas árvores treinadas com subconjuntos diferentes dos dados (bagging). Para regressão, a previsão final é a média das árvores; para classificação, é a proporção de árvores que votam em cada classe, o que fornece naturalmente uma estimativa de probabilidade. Random Forest captura relações não lineares entre os atributos e o alvo e permite estimar a importância relativa de cada atributo, com base na redução de impureza proporcionada por cada divisão (BREIMAN, 2001).

Redes Neurais (MLP): o Perceptron Multicamadas (MLP) é composto por camadas de neurônios conectados, com funções de ativação não lineares (neste trabalho, ReLU) entre as camadas ocultas. Os pesos são ajustados por retropropagação do erro, minimizando a função de perda no conjunto de treino. MLPs conseguem aproximar relações não lineares complexas, mas exigem maior cuidado com normalização dos dados e ajuste de hiperparâmetros (GOODFELLOW; BENGIO; COURVILLE, 2016).

2.3. Pré-processamento e vazamento de dados

A normalização (StandardScaler) transforma cada atributo para ter média zero e desvio padrão um. Ela é necessária para modelos baseados em gradiente (Regressão Logística e MLP), cuja convergência é sensível à escala dos atributos, mas não é necessária para modelos baseados em árvores (Random Forest), que são invariantes a transformações monotônicas dos atributos.

Vazamento de dados (data leakage) ocorre quando um atributo de entrada contém, direta ou indiretamente, informação do próprio alvo que não estaria disponível no momento da previsão real. Esse problema produz métricas de desempenho artificialmente elevadas e modelos inutilizáveis em produção. A identificação e a correção de vazamento de dados foi uma das decisões metodológicas centrais deste trabalho, discutida na Seção 3.4.

2.4. Métricas de avaliação

Para a regressão, foram utilizadas três métricas complementares: o Erro Absoluto Médio (MAE), que mede o erro médio nas mesmas unidades do alvo (kW); a Raiz do Erro Quadrático Médio (RMSE), também em kW, mas que penaliza mais fortemente erros grandes; e o coeficiente de determinação (R^2), que mede a fração da variância do alvo explicada pelo modelo, numa escala adimensional de 0 a 1 (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Para a classificação, foram utilizadas a acurácia, que mede a proporção geral de previsões corretas, e a área sob a curva ROC (AUC-ROC), que mede a capacidade do modelo de ordenar corretamente as classes independentemente do limiar de decisão, sendo mais robusta a desbalanceamento entre classes. A matriz de confusão e as métricas de precisão e revocação por classe foram utilizadas para uma análise mais detalhada dos erros de cada modelo.

3. Metodologia

3.1. Conjunto de dados

Foi utilizado o conjunto de dados público Solar Power Generation Data, disponível no Kaggle (ANIKANNAL, 2020), contendo registros de duas usinas solares fotovoltaicas (Planta 1 e Planta 2), coletados em intervalos de 15 minutos durante 34 dias. Para cada planta, há dois arquivos: um de geração, com leituras por inversor (potência DC, potência AC, rendimento diário e rendimento total), e um de sensores climáticos, com irradiação, temperatura ambiente e temperatura do módulo. Cada planta possui em torno de 20 inversores, cada um gerando uma leitura a cada 15 minutos, enquanto o sensor climático gera apenas uma leitura por planta no mesmo intervalo.

3.2. Pré-processamento

O pré-processamento seguiu as seguintes etapas. Primeiro, os timestamps foram convertidos para o tipo datetime, permitindo extração de componentes temporais e junções corretas entre tabelas. Em seguida, as leituras de geração de todos os inversores de uma planta foram agregadas por soma para cada instante de tempo, produzindo uma série no mesmo nível de granularidade dos sensores climáticos. As tabelas de geração agregada e de sensores foram então unidas (inner join) pelo timestamp, e os dados das duas plantas foram combinados em um único conjunto, identificado pela coluna PLANT_ID.

Não foram encontrados valores ausentes no conjunto de dados. Para o tratamento de valores anômalos, optou-se por não aplicar o método de intervalo interquartil (IQR), pois a distribuição da potência gerada é naturalmente bimodal: próxima de zero durante a noite e com ampla variação durante o dia. A aplicação do IQR removeria justamente os picos de geração ao meio-dia, exatamente os dados mais relevantes para o modelo, classificando-os erroneamente como outliers. Em vez disso, foi feita apenas uma verificação de plausibilidade física, removendo eventuais leituras de potência negativa, o que não é fisicamente possível para geração de energia.

Por fim, foram criados atributos derivados do timestamp: hora do dia, mês, dia da semana e período do dia (madrugada, manhã, tarde, noite), utilizados na análise exploratória e na modelagem.

3.3. Definição do problema e dos alvos

O sistema aborda duas tarefas complementares, ambas referentes ao mesmo objetivo: estimar a geração de energia a partir das condições climáticas, de modo que o resultado sirva tanto para previsão (planejamento) quanto para monitoramento (comparação entre geração esperada e real).

O alvo de regressão é AC_POWER, a potência instantânea em corrente alternada (kW). O alvo de classificação, denominado BAIXA_GERACAO, é binário e indica se um determinado período (com sol presente, IRRADIATION > 0,1) apresenta geração abaixo do 40º percentil da distribuição diurna de AC_POWER daquela planta. O limiar foi calculado separadamente para cada planta (12.855 kW para a Planta 1 e 10.674 kW para a Planta 2), pois as duas plantas operam em níveis de geração distintos, conforme discutido na Seção 4.1. A modelagem foi restrita a períodos diurnos, totalizando 2.789 amostras, das quais 1.673 (60%) foram rotuladas como geração adequada e 1.116 (40%) como baixa geração.

3.4. Seleção de atributos

Os atributos utilizados em ambas as tarefas foram: IRRADIATION (irradiação solar), MODULE_TEMPERATURE (temperatura do módulo fotovoltaico), AMBIENT_TEMPERATURE (temperatura ambiente), HORA (hora do dia) e PLANT_ID (identificador da planta). Não foram utilizados a potência DC (DC_POWER) nem a eficiência de conversão DC/AC como atributos.

Essa exclusão foi uma decisão metodológica central do trabalho. A potência DC é medida pelo próprio inversor no mesmo instante da potência AC, sendo quase proporcional a ela; utilizá-la como atributo tornaria a tarefa de regressão trivial (na prática, uma simples razão), produzindo um R^2 próximo de 1, mas um modelo que só funciona quando a usina já está gerando, pois a leitura DC do futuro não existe no momento da previsão. Ao restringir os atributos a variáveis exclusivamente climáticas, o modelo passa a ser aplicável tanto à previsão de geração futura (quando ainda não há nenhuma leitura do inversor) quanto ao monitoramento da geração atual, por meio da comparação entre o valor previsto e o valor real medido.

3.5. Divisão treino/teste e normalização

Os dados foram divididos em 80% para treino (2.231 amostras) e 20% para teste (558 amostras), com semente fixa (random_state = 42) para reprodutibilidade. Para a tarefa de classificação, a divisão foi estratificada, preservando a proporção entre as classes em treino e teste. Para os modelos de Regressão Logística e MLP, os atributos foram normalizados com StandardScaler, ajustado apenas no conjunto de treino e aplicado ao conjunto de teste; Regressão Linear e Random Forest utilizaram os atributos em sua escala original.

3.6. Modelos e hiperparâmetros

Para a regressão, foram comparados: Regressão Linear (parâmetros padrão, como referência); Random Forest Regressor, com 100 árvores (n_estimators = 100); e MLP Regressor, com três camadas ocultas de 128, 64 e 32 neurônios, ativação ReLU e parada antecipada (early stopping) com base em um conjunto de validação interno.

Para a classificação, foram comparados: Regressão Logística, com até 1.000 iterações; Random Forest Classifier, com 100 árvores; e MLP Classifier, com duas camadas ocultas de 64 e 32 neurônios e parada antecipada. Em ambos os modelos lineares/baseados em árvore para classificação, foi utilizado o parâmetro class_weight = 'balanced', que ajusta o peso de cada classe no treinamento de forma inversamente proporcional à sua frequência, compensando o leve desbalanceamento entre as classes (60% / 40%).

3.7. Avaliação

Os modelos de regressão foram avaliados no conjunto de teste por RMSE, MAE e R^2. Os modelos de classificação foram avaliados por acurácia, AUC-ROC,

matriz de confusão e relatório de precisão/revocação por classe. Em ambas as tarefas, para cada algoritmo, foi também calculada a importância dos atributos do modelo Random Forest, permitindo identificar quais variáveis climáticas mais influenciam a geração de energia e a ocorrência de períodos de baixa geração.

4. Resultados

4.1. Análise exploratória dos dados

A análise exploratória foi orientada por três perguntas, diretamente ligadas ao objetivo do sistema: (i) o que determina a geração de energia; (ii) como a geração varia ao longo do dia; e (iii) as duas plantas geram em níveis semelhantes ou diferentes.

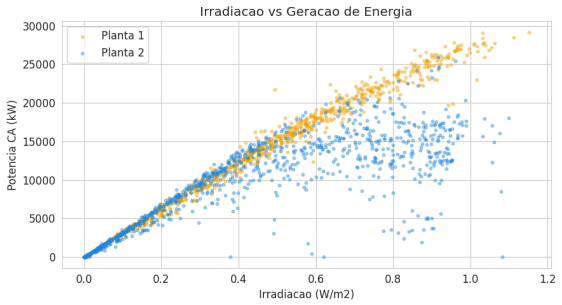


Figura 1. Relação entre irradiação solar e potência CA gerada, por planta.

A Figura 1 mostra que a geração de energia (AC_POWER) cresce de forma aproximadamente linear com a irradiação solar, em ambas as plantas. Esse resultado confirma a irradiação como o principal fator determinante da geração e justifica sua inclusão como o atributo central dos modelos de regressão e classificação.

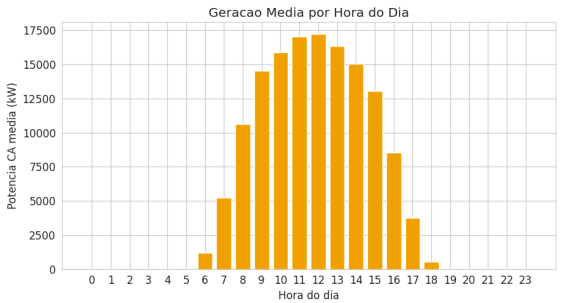


Figura 2. Potência CA média por hora do dia.

A Figura 2 mostra o ciclo diurno da geração: a potência média é praticamente nula entre 19h e 5h, e atinge seu pico próximo ao meio-dia. Essa relação entre hora e geração tem formato de sino (não monotônico), o que faz com que a correlação linear entre HORA e AC_POWER seja próxima de zero, mesmo havendo uma relação forte: uma relação não linear que modelos baseados em árvores e redes neurais capturam melhor do que a Regressão Linear.

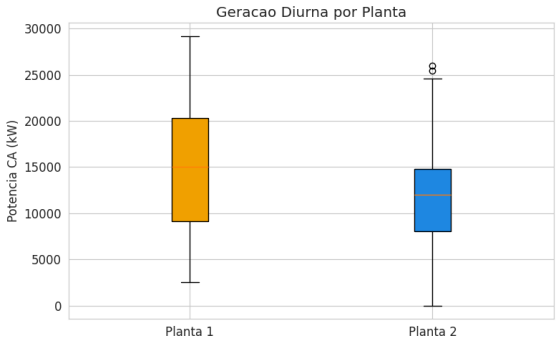


Figura 3. Distribuição da potência CA diurna por planta.

A Figura 3 mostra que as duas plantas operam em níveis de geração distintos: a Planta 1 apresenta, no período diurno, valores de potência CA tipicamente mais altos que a Planta 2. Essa diferença justifica o uso de PLANT_ID como atributo e a definição do limiar de baixa geração separadamente para cada planta (Seção 3.3).

Síntese da análise exploratória

Em resumo, a irradiação é o principal fator de geração; a hora do dia captura o ciclo diurno por meio de uma relação não linear; e as duas plantas operam em níveis diferentes, justificando o uso de PLANT_ID. Essas três conclusões orientaram diretamente a seleção de atributos descrita na Seção 3.4.

4.2. Resultados da regressão (geração esperada)

A Tabela 1 e a Figura 4 apresentam a comparação dos três modelos de regressão no conjunto de teste.

Modelo	RMSE (kW)	MAE (kW)	R^2
Regressão Linear	3337,25	2434,03	0,709
Random Forest	2410,32	1332,18	0,848
MLP (Rede Neural)	2412,51	1361,62	0,848

Tabela 1. Comparação dos modelos de regressão.

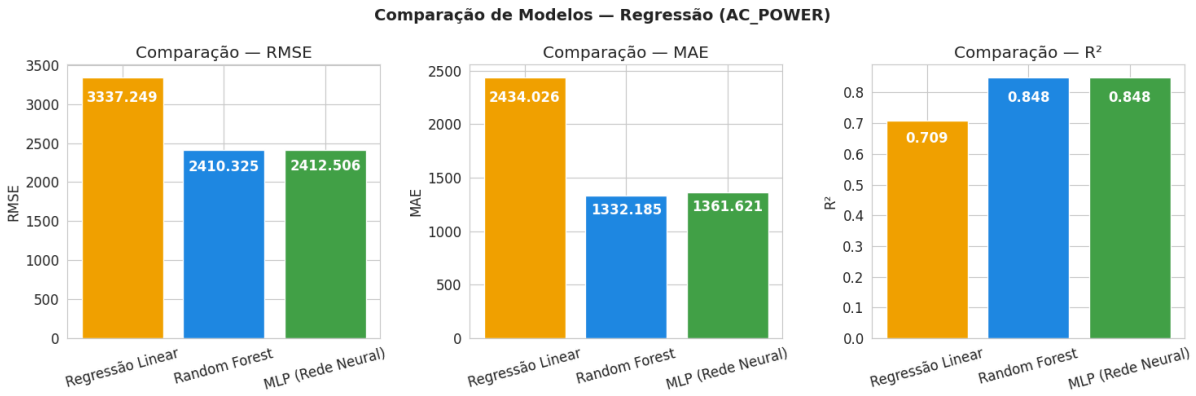


Figura 4. Comparação de RMSE, MAE e R² entre os modelos de regressão.

O Random Forest obteve o melhor desempenho (R^2 = 0,848; MAE = 1.332 kW), seguido de perto pelo MLP (R^2 = 0,848; MAE = 1.362 kW). A Regressão Linear apresentou desempenho sensivelmente inferior (R^2 = 0,709; MAE = 2.434 kW). Essa diferença é coerente com a não linearidade discutida na Figura 2: a relação entre HORA e a geração tem formato de sino, e as variáveis climáticas (irradiação e temperaturas) são fortemente correlacionadas entre si, dificultando a interpretação dos coeficientes de um modelo linear.

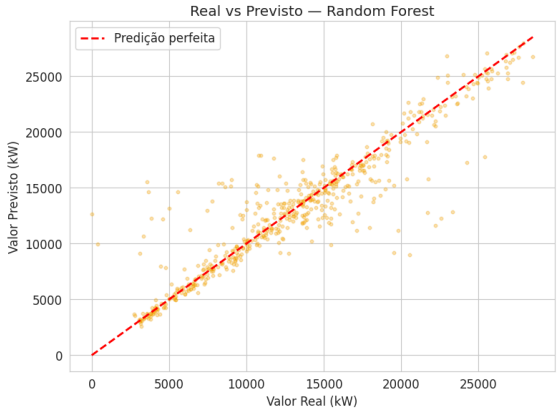


Figura 5. Geração real vs prevista (Random Forest).

A Figura 5 mostra a dispersão entre os valores reais e previstos pelo melhor modelo (Random Forest), com os pontos concentrados próximos à diagonal de previsão perfeita, indicando boa aderência mesmo sem o uso da potência DC como atributo.

Modelo	Acurácia	AUC-ROC
Regressão Logística	0,855	0,930
Random Forest	0,928	0,975
MLP (Rede Neural)	0,900	0,954

Tabela 3. Comparação dos modelos de classificação.

Atributo	Importância
IRRADIATION	0,794
PLANT_ID	0,122
AMBIENT_TEMPERATURE	0,036
MODULE_TEMPERATURE	0,032
HORA	0,016

Tabela 2. Importância dos atributos: regressão (Random Forest).

A irradiação domina a importância dos atributos (0,794), seguida por PLANT_ID (0,122), que captura a diferença de nível de geração entre as plantas observada na Figura 3. Chama atenção a baixa importância de HORA (0,016): ela não é irrelevante, mas redundante na presença da irradiação. A hora afeta a geração apenas indiretamente, determinando quanto sol incide em cada momento, enquanto a irradiação mede esse efeito diretamente. Quando a irradiação já está disponível como atributo, a hora deixa de agregar informação adicional relevante.

4.3. Resultados da classificação (baixa geração)

A Tabela 3 e as Figuras 6 e 7 apresentam a comparação dos três modelos de classificação no conjunto de teste, para a previsão de períodos de baixa geração.

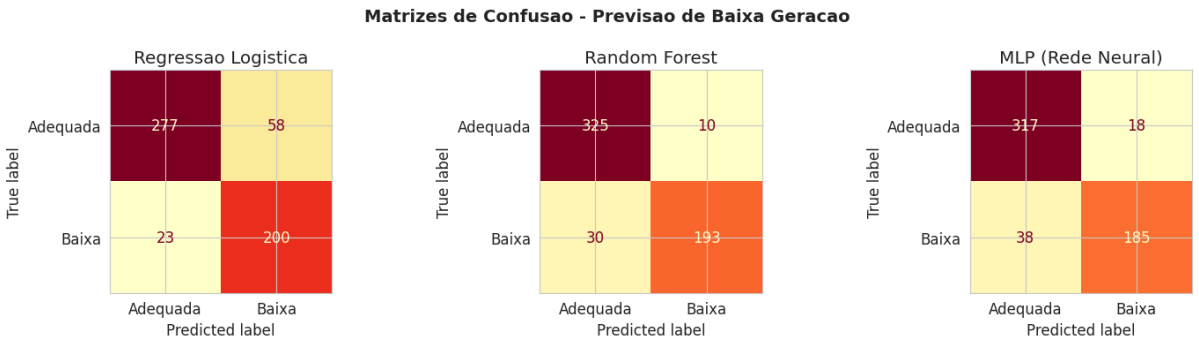


Figura 6. Matrizes de confusão dos três modelos de classificação.

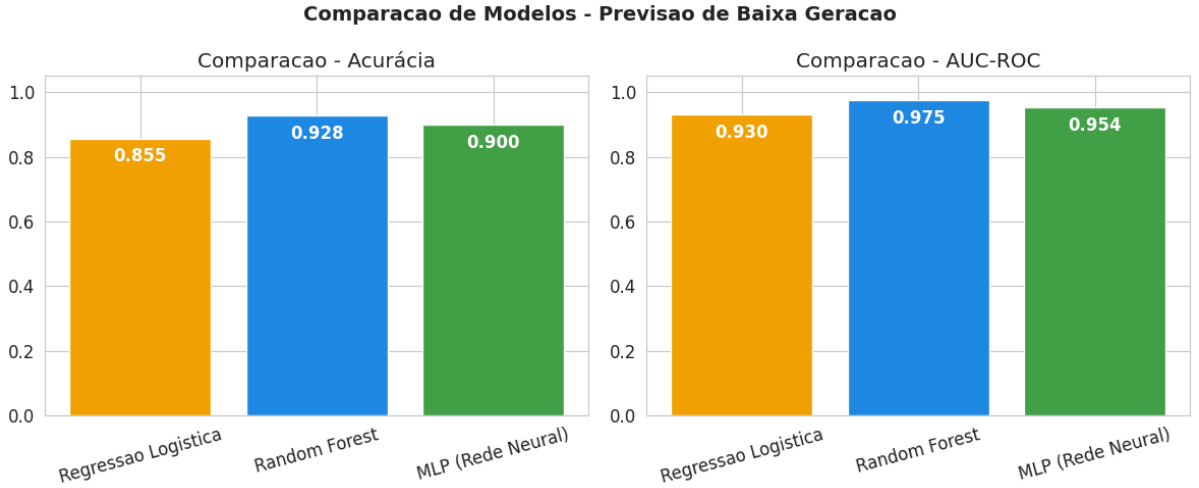


Figura 7. Comparação de acurácia e AUC-ROC entre os modelos de classificação.

O Random Forest novamente apresentou o melhor desempenho (acurácia = 0,928; AUC-ROC = 0,975), seguido pelo MLP (0,900 / 0,954) e pela Regressão Logística (0,855 / 0,930). Os valores de AUC-ROC, todos acima de 0,93, indicam que as condições climáticas separam bem os períodos de baixa geração dos períodos de geração adequada, mesmo no modelo mais simples.

Atributo	Importância
IRRADIATION	0,535
MODULE_TEMPERATURE	0,248
AMBIENT_TEMPERATURE	0,115
HORA	0,074
PLANT_ID	0,029

Tabela 4. Importância dos atributos: classificação (Random Forest).

Na classificação, a irradiação permanece o atributo mais importante (0,535), porém com participação bem maior da temperatura do módulo (0,248) em comparação à regressão (0,032). Isso sugere que, para distinguir períodos de baixa geração, a combinação de baixa irradiação com temperaturas elevadas do módulo é um padrão relevante, possivelmente associado a perdas de eficiência por efeito térmico em horários de pico.

4.4. Protótipo de interface: painel de apoio à decisão

Foi desenvolvido um painel interativo (ipywidgets), no qual o gestor seleciona a planta e ajusta as condições climáticas (irradiação, temperaturas e hora). O painel retorna a geração CA esperada (regressão) e a previsão de baixa geração (classificação). Opcionalmente, o gestor pode informar a geração real medida; nesse caso, o sistema calcula o desvio entre o esperado e o real e emite uma recomendação.



Figura 8. Painel no modo planejamento (sem leitura real).

A Figura 8 ilustra o modo de planejamento: para a Planta 1, às 12h, com irradiação 0,85, o sistema prevê geração esperada de 24.426 kW e probabilidade de baixa geração de 0%, retornando a recomendação "Operação normal". Esse modo é útil quando ainda não há leitura do inversor, por exemplo para estimar a geração a partir de uma previsão do tempo.



Figura 9. Painel no modo monitoramento (com leitura real).

A Figura 9 ilustra o modo de monitoramento: para a Planta 2, nas mesmas condições climáticas (12h, irradiação 0,85), a geração esperada é de 14.069 kW, mas a geração real informada é de apenas 5.000 kW, um desvio de 64,5%. Como o desvio supera o limiar de 15% definido na regra de decisão, o sistema emite a recomendação "Ação necessária", sugerindo possível falha de equipamento ou sujeira nos painéis.

Esse exemplo ilustra a complementaridade entre os dois modelos: o classificador, baseado apenas no clima, indicaria condições normais (já que o clima por si só não muda em caso de falha de equipamento); é a comparação entre a geração esperada (regressão) e a geração real que permite detectar o desvio. Assim, a regressão fornece a referência de geração esperada (usada tanto para previsão quanto como base de comparação no monitoramento), enquanto a classificação fornece um sinal binário complementar, útil para o planejamento de manutenções em janelas de baixa geração prevista.

5. Conclusão

Este trabalho desenvolveu um sistema de apoio à decisão para usinas solares fotovoltaicas, integrando análise exploratória, modelos de regressão e classificação e um protótipo de interface, todos orientados por um único objetivo: estimar a geração de energia a partir de variáveis climáticas, de modo que o mesmo modelo sirva tanto para previsão quanto para monitoramento da usina. O Random Forest apresentou o melhor desempenho em ambas as tarefas ($R^2 = 0{,}848$ na regressão; acurácia = 0,928 e AUC-ROC = 0,975 na classificação) e foi o modelo adotado no relatório e na interface final.

5.1. Dificuldades

- Durante a análise exploratória, identificou-se que as duas plantas registram a potência DC em escalas diferentes (a eficiência aparente de conversão DC/AC era de aproximadamente 10% na Planta 1 e 97% na Planta 2), um problema de qualidade de dados que exigiu investigação cuidadosa antes de qualquer decisão de modelagem envolvendo essa variável.
- A definição do alvo de classificação passou por mais de uma reformulação. Uma primeira versão classificava "dia bom" ou "dia ruim" com base na geração diária absoluta, mas esse critério não era comparável entre plantas de capacidades diferentes. Uma segunda versão definia anomalias de eficiência a partir da razão AC/DC, mas dependia da potência DC, sujeita ao problema de escala citado e à mesma leitura instantânea que tornaria o modelo inutilizável para previsão. A versão final, BAIXA_GERACAO, resolveu ambos os problemas ao se basear apenas em variáveis climáticas e em limiares definidos por planta.
- A primeira tentativa de tratamento de valores anômalos, baseada no método IQR, removia cerca de 18% das leituras de potência DC, exatamente os picos de geração em torno do meio-dia, que são valores legítimos em uma distribuição naturalmente bimodal (zero à noite, alta durante o dia). Esse tratamento foi substituído por uma verificação de plausibilidade física (ausência de valores negativos).

5.2. Aprendizados

- O Random Forest mostrou-se um modelo robusto para ambas as tarefas, exigindo pouco ajuste de hiperparâmetros e fornecendo, como subproduto, a importância dos atributos, útil tanto para validar a análise exploratória quanto para explicar os resultados ao usuário final.
- A identificação de vazamento de dados é uma etapa crítica quando o alvo é derivado de outras colunas do conjunto de dados; nesse projeto, isso motivou a remoção da potência DC e da eficiência de conversão como atributos.
- Correlação linear e importância de atributos medem coisas diferentes: a hora do dia apresenta correlação linear próxima de zero com a geração, mas isso reflete o formato não monotônico (em sino) dessa relação, e não a ausência de relação. Já a baixa importância de HORA no Random Forest tem outra causa: redundância na presença da irradiação, que é a causa mais direta da geração.
- O parâmetro class_weight = 'balanced' foi útil para lidar com o desbalanceamento moderado entre as classes (60%/40%) na tarefa de classificação, e a normalização (StandardScaler) foi necessária para a convergência adequada da Regressão Logística e do MLP, mas não dos modelos baseados em árvores.

5.3. Limitações e trabalhos futuros

- A temperatura do módulo, utilizada como atributo, é parcialmente endógena: ela depende da própria operação da usina e da exposição ao sol. Uma versão de previsão estritamente antecipada deveria utilizar apenas variáveis meteorológicas previstas

(irradiação e temperatura ambiente previstas), por exemplo via integração com uma API de previsão do tempo, como a do INMET.

- A tarefa de classificação é parcialmente redundante com a regressão, já que "baixa geração" poderia, em princípio, ser obtida aplicando um limiar sobre a previsão contínua. Ela foi mantida como um sinal binário de apoio ao planejamento, mas seu ganho de informação em relação à regressão é limitado.
- O limiar de baixa geração (40º percentil) é uma escolha estatística de conveniência, e não um critério de negócio; um limiar definido pela operação (por exemplo, a produção mínima economicamente relevante) seria mais significativo.
- O conjunto de dados cobre apenas 34 dias, sem representar variações sazonais ao longo do ano, e a generalização para novas plantas depende de recalibração do atributo PLANT_ID.
- Como trabalhos futuros, propõe-se: (i) validação temporal, treinando com os primeiros dias e testando nos últimos, em vez de divisão aleatória; (ii) normalização da geração pelo Performance Ratio, tornando o monitoramento adimensional e portável entre usinas de capacidades diferentes; (iii) quantificação de incerteza, fornecendo intervalos de previsão em vez de valores pontuais; (iv) ajuste sistemático de hiperparâmetros via validação cruzada (GridSearchCV/RandomizedSearchCV); e (v) integração com fontes de previsão meteorológica para viabilizar a previsão antecipada da geração.

Referências

ANIKANNAL, V. Solar Power Generation Data. Kaggle, 2020. Disponível em: https://www.kaggle.com/datasets/anikannal/solar-power-generation-data.

BREIMAN, L. Random Forests. Machine Learning, v. 45, n. 1, p. 5–32, 2001.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. Cambridge: MIT Press, 2016.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2. ed. New York: Springer, 2009.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.